

Laporan Teknis Data Science

Coding Camp 2026 powered by DBS Foundation

ID Tim Capstone Project : CC26 - PSU107

Judul Proyek : Deteksi Phishing Message Bahasa Indonesia Berbasis Natural
Language Process (NLP) Menggunakan Algoritma TextCNN

Tema yang Dipilih : Revolusi Teknologi Keuangan (Fintech) untuk Generasi Muda

List Anggota :

1. CFCC868D6Y1456 - Evan Akbarudin - Full-Stack Web Developer - [**Aktif**]
2. CFCC211D6Y1552 - Muhamad Hafiudin Bagir - Full-Stack Web Developer - [**Aktif**]
3. **CDCC010D6X2007 - Feyza Hasna Shabrina - Data Scientist - [**Aktif**]**
4. **CDCC011D6Y2756 - Rasendriya Nandana Kurniawan- Data Scientist - [**Aktif**]**
5. CACC009D6X0482 - Novia Dwi Cahyanti - AI Engineer - [**Aktif**]
6. CACC009D6X2478 - Ranti Natasha Putri - AI Engineer - [**Aktif**]

BAB 1

PROBLEM DISCOVERY & PENDAHULUAN

1.1 Latar Belakang Masalah

Indonesia saat ini menghadapi ancaman serius dari maraknya penipuan digital berbasis pesan singkat atau dikenal sebagai *smishing* (SMS Phishing). Berdasarkan laporan *Global Fraud Index 2025*, Indonesia menempati posisi kedua dari 112 negara yang paling rentan terhadap penipuan dengan skor 6,53 dari 10. Kondisi ini dipertegas oleh riset *Center for Digital Society (CfDS) Universitas Gadjah Mada* yang menunjukkan bahwa 66,6% masyarakat Indonesia pernah menjadi korban penipuan digital.

Modus penipuan yang paling banyak menjerat korban adalah penipuan berkedok hadiah atau smishing sebesar 36,9%, diikuti pengiriman tautan berisi malware serta penipuan jual beli. Lebih mengkhawatirkan lagi, penelitian terhadap 1.700 responden di 34 provinsi menunjukkan bahwa SMS dan telepon masih menjadi media utama yang digunakan pelaku (64,1%). Jika dibiarkan tanpa solusi deteksi otomatis, dampak negatifnya sangat nyata: kerugian finansial yang kian besar, menurunnya kepercayaan masyarakat terhadap komunikasi digital, serta meningkatnya kerentanan kelompok dengan literasi digital rendah, khususnya lansia berusia ≥ 40 tahun yang menjadi target empuk pelaku.

1.2 Solusi Utama

Berdasarkan permasalahan di atas, tim mengembangkan SafeMessage, sebuah sistem deteksi pesan phishing berbahasa Indonesia berbasis AI yang menggunakan model TextCNN (Text Convolutional Neural Network). Sistem ini mampu mengklasifikasikan pesan mencurigakan secara otomatis dan *real-time* hanya dengan memasukkan teks pesan melalui antarmuka web yang sederhana.

Keunggulan dan nilai inovatif SafeMessage dibandingkan pendekatan konvensional:

- **Domain-specific:** model dilatih khusus pada dataset SMS/WA phishing berbahasa Indonesia — bukan sekadar mengadaptasi model bahasa Inggris
- **Multi-input TextCNN:** menggabungkan representasi teks semantik (embedding) dengan fitur numerik/biner berbasis pengetahuan domain (has_url, has_phone, has_currency, dll)
- **Generative AI terintegrasi:** memberikan rekomendasi tindakan yang dipersonalisasi kepada pengguna via Gemini/Grok API

- **Dirancang untuk inklusivitas:** antarmuka sederhana dan ramah bagi kelompok usia ≥ 40 tahun yang menjadi sasaran utama smishing

Output sistem mencakup klasifikasi pesan sebagai Phishing atau Non-Phishing, skor probabilitas risiko, dan rekomendasi tindakan otomatis berbasis AI.

1.3 Pertanyaan Bisnis (Business Questions)

Analisis data dalam proyek ini diarahkan untuk menjawab lima pertanyaan bisnis yang spesifik dan terukur:

ID	Pertanyaan Bisnis	Metrik / Alat Ukur
BQ1	Bagaimana distribusi dan keseimbangan kelas (phishing vs. normal) pada dataset, dan apakah tingkat imbalance-nya berpotensi memengaruhi performa model?	Frekuensi, persentase, imbalance ratio
BQ2	Modus dan taktik phishing apa yang paling dominan pada dataset, dan bagaimana kombinasi taktik tersebut digunakan secara bersamaan?	Frekuensi tag sub_kategori, explode kombinasi
BQ3	Seberapa besar perbedaan keberadaan fitur struktural (URL, nomor telepon, kode OTP, penyebutan rupiah) antara pesan phishing dan normal?	Korelasi Pearson, persentase per kelas
BQ4	Kata dan frasa apa yang paling khas dan diskriminatif untuk membedakan pesan phishing dari pesan normal?	TF-IDF, frekuensi kata, Word Cloud
BQ5	Apakah terdapat perbedaan signifikan secara statistik pada panjang teks antara pesan phishing dan normal, dan seberapa besar efeknya?	Uji Mann-Whitney U, rank-biserial effect size

BAB 2

DATA WRANGLING & PERSIAPAN DATA

2.1 Data Gathering (Pengumpulan Data)

Dataset dikumpulkan dari tiga sumber publik yang dipilih berdasarkan relevansi dengan konteks SMS/WA phishing berbahasa Indonesia. Diversifikasi sumber menjadi kunci untuk menghindari bias dan memastikan model dapat menggeneralisasi berbagai pola penipuan yang ada di lapangan.

No	Sumber	Jenis Data	Volume Awal	Mapping Label
1	GitHub Gist (yudiwbs)	SMS Spam Indonesia asli dari pengguna nyata	~538 baris	penipuan→1, promo→0
2	GitHub (bopbi)	SMS Spam dikategorikan per modus (prize, loan, evil, premium)	~500 baris	prize/loan/evil→1, non-promo→0
3	Kaggle (gevabriel)	Email Spam Indonesia — difilter ≤ 800 karakter	~1.200 baris (734 lolos filter)	spam→1, ham→0

Catatan: Dataset Kaggle awalnya berisi email korporat panjang (rata-rata > 1.200 karakter) yang tidak representatif untuk konteks SMS phishing Indonesia. Setelah filtering teks > 800 karakter, tersisa 734 baris yang sesuai domain. Hal ini dilakukan secara manual agar tidak ada data out-of-domain yang mengkontaminasi model.

Seluruh dataset kemudian di-merge, dilabeli ulang secara konsisten (1=phishing, 0=normal), dan diberi kolom 'sumber' untuk keperluan tracing dan stratified split berbasis domain.

2.2 Data Assessing (Penilaian Kualitas Data)

Setelah proses merge dari ketiga sumber, dilakukan pemeriksaan menyeluruh terhadap kualitas dan struktur data mentah:

Temuan Awal Dataset:

Aspek	Temuan	Detail
Jumlah baris & kolom awal	~1.813 baris, 3 kolom dasar	Sebelum filtering, deduplication, dan feature engineering
Missing values	Tidak ditemukan	Kolom teks, label, dan sumber lengkap di semua baris
Duplikat teks	41 baris ($\pm 1,2\%$)	Teks identik dengan label berbeda atau sama perlu dihapus
Tipe data tidak sesuai	Sudah sesuai	Kolom teks bertipe str, label bertipe int
Teks sangat pendek (<10 karakter)	Beberapa baris	Tidak informatif untuk model NLP, sehingga perlu difilter
Teks non-Bahasa Indonesia/Melayu	Terdeteksi via langdetect	Campuran bahasa Inggris dari dataset email, sehingga perlu dibuang
Email out-of-domain (>800 karakter)	500+ baris difilter	Teks korporat panjang tidak representatif untuk SMS phishing
Distribusi kelas (imbalance)	60,3% : 39,7%	Imbalance ratio 1,52x (tergolong ringan, masih dapat diterima)

2.3 Data Cleaning (Pembersihan Data)

Berdasarkan temuan pada penilaian kualitas data, dilakukan serangkaian langkah cleaning secara berurutan dan terdokumentasi. Setiap langkah disertai justifikasi agar dapat direproduksi:

	Langkah Cleaning	Transformasi	Justifikasi
1	Filter panjang teks minimum	Hapus baris dengan teks <10 karakter	Teks terlalu pendek tidak mengandung sinyal linguistik yang berguna

	Langkah Cleaning	Transformasi	Justifikasi
2	Filter bahasa	Gunakan langdetect — hanya pertahankan id/ms	Menjaga konsistensi domain bahasa — model dilatih untuk BI/Melayu
3	Filter email out-of-domain	Hapus baris dengan teks >800 karakter dari Kaggle	Email korporat panjang tidak merepresentasikan pola SMS phishing
4	Normalisasi URL	Ganti pola http://, www., bit.ly, tsel.me, dll. → token [URL]	Model menangkap keberadaan URL secara generik tanpa tergantung domain spesifik
5	Normalisasi nomor panjang	Ganti angka ≥ 8 digit berurutan → token [NOMOR_PANJANG]	Nomor rekening dan HP panjang adalah sinyal phishing yang perlu distandarisasi
6	Normalisasi kode OTP	Ganti pola kode/verifikasi/pin + 4–7 digit → token [KODE]	Kode OTP palsu adalah taktik smishing yang umum — perlu menjadi sinyal eksplisit
7	Hapus tag HTML	Strip semua tag <...> dari teks	Artefak HTML dari dataset email yang tidak relevan untuk analisis teks
8	Hapus data duplikat	drop_duplicates() pada kolom teks_bersih	Mencegah data leakage dan bias selama training model

Pipeline Preprocessing NLP (Sastrawi):

Setelah cleaning dasar, teks diproses lebih lanjut menggunakan pipeline NLP berbahasa Indonesia untuk menghasilkan kolom teks_processed:

- Lowercase: seluruh teks dikonversi ke huruf kecil untuk standarisasi
- Pisahkan token khusus: [URL], [NOMOR_PANJANG], [KODE] diproteksi sebelum cleaning karakter

- Hapus karakter non-alfabet: angka dan simbol dihapus (kecuali token yang dilindungi)
- Stopword removal: menggunakan kamus stopwords Bahasa Indonesia dari Sastrawi
- Stemming: normalisasi morfologi kata menggunakan StemmerFactory Sastrawi
- Rekonstruksi token: token [URL], [KODE] dikembalikan ke teks setelah stemming

2.4 Data Dictionary (Kamus Data)

Berikut adalah metadata lengkap untuk setiap kolom pada dataset final yang telah bersih dan siap digunakan untuk EDA maupun pemodelan:

2.4.1 Kelompok A: Representasi Teks

Nama Fitur / Kolom	Tipe Data	Deskripsi	Keterangan
teks	str	Teks pesan SMS/WA/email asli tanpa perubahan apapun	Input utama untuk analisis dan fitur mentah
teks_bersih	str	Teks setelah cleaning dasar: URL/nomor/kode diganti token, HTML dihapus	Digunakan untuk ekstraksi fitur biner (has_url, dll)
teks_processed	str	Teks setelah preprocessing penuh: lowercase, stopwords removal, stemming, rekonstruksi token	Input teks utama untuk model TextCNN

2.4.2 Kelompok B: Label & Metadata

Nama Fitur / Kolom	Tipe Data	Deskripsi	Keterangan
label	Integer	Target klasifikasi binary: 1 = phishing, 0 = normal	Variabel target model (tidak boleh masuk fitur input)
sumber	str	Asal dataset: yudiwbs_gist, bopbi_*, kaggle_email_indo	Digunakan untuk stratified split per domain

Nama Fitur / Kolom	Tipe Data	Deskripsi	Keterangan
sub_kategori	str	Tag modus phishing berdasarkan keyword matching, pipe-separated	Contoh: hadiah phishing_url mint_data. Untuk label=0: 'normal'
domain	str	Domain asal: 'sms' atau 'email'	Hanya untuk stratified split (tidak masuk model)

2.4.3 Kelompok C: Fitur Numerik & Biner (Input Model)

Nama Fitur / Kolom	Tipe Data	Deskripsi	Keterangan
text_length	Integer	Panjang teks asli dalam jumlah karakter	Median phishing: 333 vs normal: 294
word_count	Integer	Jumlah kata dalam teks asli	Proxy kompleksitas pesan
exclamation_count	Integer	Jumlah tanda seru (!) dalam teks	Sinyal urgensi/clickbait
question_count	Integer	Jumlah tanda tanya (?) dalam teks	Sinyal manipulasi/pertanyaan retorik
digit_ratio	Float	Proporsi karakter digit dari total karakter (0–1)	Proxy kepadatan angka (nominal, kode)
avg_word_length	Float	Rata-rata panjang kata dalam teks (karakter/kata)	Proxy gaya bahasa penipuan
uppercase_ratio	Float	Proporsi huruf kapital dari total karakter (0–1)	Sinyal penekanan/urgensi palsu

Nama Fitur / Kolom	Tipe Data	Deskripsi	Keterangan
has_url	Integer (Nominal)	1 jika teks mengandung URL, 0 jika tidak	Korelasi Pearson +0,089 dengan label phishing
has_phone	Integer (Nominal)	1 jika teks mengandung nomor panjang (≥ 8 digit), 0 jika tidak	Korelasi Pearson +0,209 — sinyal terkuat positif
has_code	Integer (Nominal)	1 jika teks mengandung kode numerik 4–7 digit, 0 jika tidak	Korelasi Pearson -0,230 — normal lebih banyak OTP resmi
has_currency	Integer (Nominal)	1 jika teks menyebut rupiah/juta/ribu, 0 jika tidak	Umpan finansial pada phishing berhadiah

Summary:

1.772 Total Baris Final <i>setelah cleaning</i>	17 Total Kolom Final <i>termasuk 11 fitur input model</i>	1.069 Phishing (label=1) <i>60,3%</i>	703 Normal (label=0) <i>39,7%</i>
--	--	--	--

BAB 3

EXPLORATORY DATA ANALYSIS (EDA)

3.1 Exploratory Data Analysis (EDA)

Proses EDA dilakukan untuk memahami distribusi, pola, dan hubungan antar variabel sebelum masuk ke tahap pemodelan. EDA dilakukan dalam tiga level: univariate, bivariate, dan analisis berbasis domain.

3.1.1 Univariate Analysis: Distribusi Variabel Tunggal

Distribusi label menunjukkan kondisi sedikit tidak seimbang dengan rasio 60,3% phishing : 39,7% normal. Meskipun imbalance ratio 1,52x tergolong ringan, tetap diperhatikan dalam pemilihan metrik evaluasi model (F1-Score dan AUC-ROC diprioritaskan di atas Accuracy).

Analisis distribusi panjang teks menggunakan histogram menunjukkan distribusi right-skewed untuk kedua kelas. Pesan phishing memiliki median 333 karakter, sedikit lebih panjang dari pesan normal (median 294 karakter). Distribusi sub_kategori menunjukkan tujuh modus yang teridentifikasi, dengan 'lainnya' sebagai kategori catch-all untuk teks phishing yang tidak cocok dengan pola keyword.

3.1.2 Bivariate Analysis: Hubungan Antar Variabel

Korelasi Pearson dihitung antara semua 11 fitur yang diekstraksi terhadap label target, diurutkan berdasarkan nilai absolut korelasi:

Fitur	Korelasi Pearson	Kekuatan	Arah
has_code	-0,230	Sedang (terkuat negatif)	Normal lebih banyak OTP resmi dari bank/operator
has_phone	+0,209	Sedang (terkuat positif)	Phishing jauh lebih banyak mengandung nomor panjang
exclamation_count	+0,194	Sedang	Nada urgensi berlebihan khas phishing

Fitur	Korelasi Pearson	Kekuatan	Arah
has_url	+0,089	Lemah	Phishing lebih banyak URL, namun normal juga ada URL resmi
has_currency	positif lemah-sedang	Lemah-Sedang	Umpan finansial pada phishing
question_count	~0	Sangat Lemah	Hampir tidak berkorelasi
digit_ratio	~0	Sangat Lemah	Hampir tidak berkorelasi
uppercase_ratio	positif sangat lemah	Sangat Lemah	Hampir tidak berkorelasi

3.1.3 Analisis Berbasis Domain: Sub-Kategori Phishing

Teknik explode tag digunakan pada kolom sub_kategori untuk menghitung frekuensi setiap taktik secara individual, mengingat satu pesan bisa mengandung beberapa taktik sekaligus. Pola awal yang menarik: mayoritas pesan phishing menggabungkan minimal dua taktik (kombinasi minta_data dan phishing_url paling banyak ditemukan).


3.2 Explanatory Analysis & Visualisasi Data

Berikut adalah hasil visualisasi dan analisis explanatory untuk menjawab seluruh Business Questions yang didefinisikan:

3.2.1 BQ1: Seberapa Seimbang/Proporsional Data yang Dimiliki?

Pertanyaan ini menjadi prasyarat penting sebelum melatih model: apakah distribusi kelas seimbang atau imbalanced? Ketidakseimbangan kelas yang ekstrem dapat menyebabkan model bias ke kelas mayoritas sehingga gagal mendeteksi kelas minoritas.

Visualisasi:




1.772 Total Data	1.069 Phishing (label=1) 60,3%	703 Normal (label=0) 39,7%	1,52x Imbalance Ratio <i>ringan, dapat diterima</i>
---------------------	--------------------------------------	----------------------------------	---

💡 **Insight:** Dataset ini berisikan sebanyak 1.772 pesan, dengan didominasi oleh pesan phishing sebanyak 1,069 (60.3%) serta 703 lainnya merupakan pesan normal (39.7%). Sehingga, didapatkan nilai Imbalance ratio sebesar 1.52x — tergolong ringan dan masih dalam batas aman (threshold umum: >2x mulai bermasalah). Distribusi dataset ini masih tergolong cukup baik untuk pelatihan model klasifikasi deteksi pesan phishing. Maka dari itu, tetap disarankan untuk memantau F1-Score dan AUC-ROC agar model tidak bias ke kelas mayoritas (pesan phishing).

3.2.2 BQ2: Modus & Taktik Phishing yang Paling Dominan

Pertanyaan ini bertujuan untuk memahami taktik yang digunakan pelaku membantu prioritisasi perlindungan dan penyusunan aturan deteksi berbasis konten.


Visualisasi:



Taktik Phishing	Frekuensi	% dari Total Phishing	Interpretasi
minta_data	477	44,6%	Meminta data pribadi (PIN, OTP, nomor rekening)
phishing_url	433	40,5%	Menyisipkan URL berbahaya untuk redirect ke halaman palsu
berhadiah	289	27,0%	Umpan hadiah/undian — fokus utama penelitian ini
urgensi	245	22,9%	Mendesak korban bertindak cepat agar tidak berpikir
lainnya	199	18,6%	Modus yang tidak cocok dengan keyword yang terdefinisi
pinjaman	107	10,0%	Penawaran pinjaman ilegal dengan syarat mudah
sosial_eng	86	8,0%	Rekayasa sosial (berpura-pura jadi anggota keluarga)

Top Kombinasi Taktik:

Visualisasi:



Kombinasi Taktik	Frekuensi	Interpretasi
berhadiah, phishing_url, minta_data	124	Terlengkap: hadiah, link, minta data sekaligus
minta_data (tunggal)	110	Pure data theft
phishing_url (tunggal)	103	Pure link phishing
phishing_url, minta_data	65	Link + minta data
urgensi (tunggal)	65	Pure urgency tactic
berhadiah (tunggal)	59	Pure prize phishing
urgensi, minta_data	33	Desak + minta data
berhadiah, minta_data	32	Hadiah + minta data


 **Insight:** Pesan berjenis minta_data merupakan pesan yang paling dominan pada dataset ini, dengan total sebanyak 477 pesan (44.6%), diikuti oleh phishing_url sebanyak 433 pesan (40.5%), dan berhadiah sebanyak (289) pesan (27.0%), Adapun kombinasi taktik pesan phishing yang paling umum adalah kombinasi pesan berhadiah, tautan phishing, serta meminta data pribadi, diikuti oleh pesan yang hanya meminta data pribadi

serta pesan yang hanya mencantumkan tautan phishing. Hal ini menunjukkan bahwa taktik meminta data pribadi, memberikan tautan phising, serta beberapa kombinasi taktik phising cenderung sering dilakukan untuk menipu banyak orang.

3.2.3 BQ3: Apakah URL, Nomor Panjang & Fitur Lain Menjadi Indikator Kuat Phishing?

Pertanyaan ini menentukan fitur mana yang paling informatif untuk model klasifikasi. Korelasi Pearson dihitung untuk semua 11 fitur terhadap label, mencakup fitur numerik (text_length, word_count, exclamation_count, question_count, digit_ratio, avg_word_length, uppercase_ratio) maupun fitur biner (has_url, has_phone, has_code, has_currency).

Visualisasi:



Fitur	Korelasi Pearson	Kekuatan	Arah & Interpretasi
has_code	-0,230	Sedang (terkuat negatif)	Normal lebih banyak mengandung kode OTP resmi dari bank/operator


Fitur	Korelasi Pearson	Kekuatan	Arah & Interpretasi
has_phone	+0,209	Sedang (terkuat positif)	Phishing 7,2x lebih banyak mengandung nomor panjang palsu
exclamation_count	+0,194	Sedang	Tanda seru berlebihan mencerminkan nada urgensi palsu di phishing
has_url	+0,089	Lemah	Phishing 3,2x lebih banyak mengandung URL berbahaya
has_currency	positif lemah-sedang	Lemah-Sedang	Phishing lebih banyak menyebut nominal uang sebagai umpan
question_count	~0	Sangat Lemah	Hampir tidak berkorelasi (kurang informatif sendiri)
digit_ratio	~0	Sangat Lemah	Hampir tidak berkorelasi (kurang informatif sendiri)
uppercase_ratio	positif sangat lemah	Sangat Lemah	Hampir tidak berkorelasi (kurang informatif sendiri)

 **Insight:** Fitur `has_code` memiliki korelasi negatif terkuat (-0,230), menandakan bahwa pesan normal justru lebih sering mengandung kode numerik — kemungkinan besar berupa kode OTP resmi dari bank/operator. Di sisi phishing, `has_phone` (+0,209) dan `exclamation_count` (+0,194) menjadi dua sinyal terkuat: pola penipuan menyertakan nomor kontak palsu dan nada urgensi berlebihan. `has_url` (+0,089) berkontribusi positif namun tidak dominan karena pesan normal pun kadang menyertakan URL resmi. Fitur `question_count`, `digit_ratio`, dan `uppercase_ratio` hampir tidak berkorelasi sehingga kurang informatif jika digunakan sendiri.

3.2.4 BQ4: Kata dan Frasa Apa yang Paling Sering Muncul di Phishing vs Normal?

Pertanyaan ini berfokus pada pemahaman pola linguistik yang dapat dijadikan fitur untuk deteksi otomatis.

Visualisasi:




Kelas	Kata Paling Dominan (Frekuensi & TF-IDF)	Interpretasi
Phishing ●	[url], kirim, klik, com, situs, hadiah, selamat, menang, verifikasi, segera	URL dan kata aksi langsung mendominasi; mengarahkan korban membagi info pribadi
Normal ●	vince, terima, enron, kasih, ect, hpl, deal, meter, market, gas	Kata korporat (Enron) dan kata sopan (terima kasih); lebih baku dan formal

Insight: Pada top kata kategori phishing, tautan url menjadi salah satu unsur yang paling sering muncul dalam pesan, diikuti oleh kata ' kirim', 'klik','com', dan 'situs'.Sedangkan pada kategori pesan normal, kata 'vince','terima','enron','kasih', dan 'ect' menjadi kata yang paling sering muncul dalam teks pesan. Hal ini menunjukkan bahwa pesan phishing lebih cenderung mengarahkan penerima pesan untuk melakukan sesuatu yang dapat memberikan informasi rahasia yang penting kepada pengirim pesan.Berbeda dengan pesan normal, kata-kata yang muncul cenderung lebih baku beserta kata 'terima' dan 'kasih'.Hal tersebut mendukung hasil TF-IDF yang memperlihatkan bahwa penggunaan kata-kata yang dapat menggaet orang awam untuk membagi informasi pribadi cenderung mengarahkan kepada pesan phishing, serta penggunaan kata-kata yang lebih bersifat korporat mengarahkan kepada pesan normal.

3.2.5 BQ5: Apakah Panjang Teks Pesan Phishing Berbeda Signifikan dengan Normal?

Visualisasi:



333	294	$3,49 \times 10^{-2}$	-0,059	$3,71 \times 10^{-1}$ p-value (kata)
-----	-----	-----------------------	--------	---

Median Karakter Phishing karakter	Median Karakter Normal karakter	p-value (karakter) signifikan ($p < 0,05$)	Effect Size (rank-biserial) sangat kecil	<i>tidak signifikan</i>
-----------------------------------	---------------------------------	--	--	-------------------------

Fitur	U Statistic	p-value	Signifikan?	Effect Size (rb)
Jumlah Karakter	Besar	$3,49 \times 10^{-2}$ (0,035)	Ya ($p < 0,05$)	-0,059
Jumlah Kata	Besar	$3,71 \times 10^{-1}$ (0,371)	Tidak ($p > 0,05$)	-

 **Insight:** Uji Mann-Whitney U menunjukkan adanya perbedaan menarik antara metrik karakter dan kata. Pada fitur Jumlah Karakter, perbedaan panjang teks bersifat signifikan secara statistik, yaitu $p = 3.4912 * 10^{-2}$ (lebih kecil dari $\alpha = 0.05$). Nilai median karakter pada pesan phishing (333) memang sedikit lebih panjang dibandingkan pesan normal (294). Namun, efek pembeda ini tergolong lemah karena memiliki effect size yang sangat kecil (rank-biserial = -0.059).

Sementara itu, pada fitur Jumlah Kata, perbedaan antara pesan phishing (median = 51) dan normal (median = 47) dinyatakan tidak signifikan secara statistik, yaitu $p = 3.7142 * 10^{-1}$ (lebih besar dari $\alpha = 0.05$).

Maka dapat disimpulkan bahwa meskipun jumlah karakter berbeda signifikan, nilai effect size yang sangat kecil serta tidak signifikannya jumlah kata menunjukkan bahwa fitur panjang teks tidak cukup andal jika digunakan sendirian untuk klasifikasi, sehingga wajib dikombinasikan dengan fitur berbasis konten (seperti TF-IDF).

BAB 4

FEATURE ENGINEERING & EKSPERIMEN A/B TESTING

4.1 Feature Engineering

Feature engineering dilakukan untuk menghasilkan fitur-fitur baru yang lebih informatif bagi model, dengan memanfaatkan pengetahuan domain tentang ciri khas pesan phishing berbahasa Indonesia. Model TextCNN menggunakan pendekatan multi-input yang menggabungkan representasi teks semantik dengan fitur numerik/biner terstruktur.

4.1.1 Fitur Numerik Kontinu

Fitur Baru	Tipe	Formula / Metode Ekstraksi	Justifikasi Domain
text_length	Integer	len(teks)	Phishing cenderung lebih elaboratif: lebih panjang dari normal
word_count	Integer	len(teks.split())	Proxy kompleksitas: phishing menggunakan lebih banyak kata bujukan
exclamation_count	Integer	teks.count('!')	Tanda seru berlebihan adalah ciri khas clickbait dan phishing
question_count	Integer	teks.count('?')	Pertanyaan retorik digunakan untuk memanipulasi korban
digit_ratio	Float	$\text{sum}(c.\text{isdigit() for } c) / \text{len}(\text{teks})$	Proxy kepadatan angka (nominal rupiah, kode rekening)
avg_word_length	Float	$\text{mean}([\text{len}(w) \text{ for } w \text{ in teks.split()}])$	Gaya bahasa phishing cenderung menggunakan kata yang lebih pendek
uppercase_ratio	Float	$\text{sum}(c.\text{isupper() for } c) / \text{len}(\text{teks})$	Huruf kapital berlebihan = penekanan urgensi palsu

4.1.2 Fitur Biner (0/1): Berbasis Regex dari Teks Asli

Fitur Baru	Tipe	Regex / Pattern (dari kolom teks)	Korelasi Pearson	Interpretasi
has_url	Integer (biner)	<code>http[s]?:/\S+ www\.\S+ bit\.\ly/\S+ tsel\.\me/\S+</code>	+0,089	Phishing 3,2x lebih banyak mengandung URL berbahaya
has_phone	Integer (biner)	<code>\b\d{8,}\b</code> (nomor digit ≥ 8)	+0,209	Phishing 7,2x lebih banyak — sinyal terkuat positif kedua
has_code	Integer (biner)	<code>\b\d{4,7}\b</code> (kode digit 4–7)	-0,230	Normal lebih banyak OTP resmi — sinyal terkuat negatif
has_currency	Integer (biner)	<code>rp\.\.?s?\d rupiah juta ribu</code>	positif sedang	Umpan finansial khas phishing berhadiah dan pinjaman

4.1.3 Fitur Kategorikal: Sub-Kategori Modus Phishing

Fitur sub_kategori diekstraksi menggunakan kamus keyword POLA_PHISHING yang dirancang berdasarkan pengetahuan domain tentang modus phishing SMS Indonesia. Satu pesan dapat memiliki beberapa tag sekaligus (pipe-separated):

Kategori	Keyword Representatif	Contoh Pesan
berhadiah	selamat, menang, terpilih, hadiah, undian, pemenang	"Selamat! Nomor Anda terpilih sebagai pemenang undian berhadiah Rp50jt..."
pinjaman	pinjaman, kredit, kta, bunga, jaminan, dana tunai, bpkb	"Butuh dana cepat? Pinjaman tanpa jaminan, bunga 0%, cair 1 hari..."
urgensi	segera, buruan, jatuh tempo, sebelum, hari ini, terbatas	"SEGERA konfirmasi sebelum 24 jam atau hadiah hangus!"
sosial_eng	mama, papa, ayah, bapak, nomor baru, masalah, tolong	"Ma, ini nomor baru aku. HP lama rusak. Tolong kirimin pulsa dulu..."
phishing_url	[url], klik, blogspot, verifikasi, website	"Klik [URL] sekarang untuk verifikasi dan ambil hadiahmu!"

Kategori	Keyword Representatif	Contoh Pesan
minta_data	pin, rekening, transfer, bca, bri, bni, [kode], [nomor_panjang]	"Konfirmasi nomor rekening BCA Anda agar hadiah dapat ditransfer..."

4.1.4 Strategi Split Dataset (Stratified 80/10/10):

Dataset di-split secara stratified terpisah per domain (SMS dan email) untuk memastikan distribusi kelas dan representasi domain proporsional di semua subset. Validasi data leakage dilakukan eksplisit setelah augmentasi.

Subset	Proporsi	Strategi Split	Fungsi
Train	80%	Stratified per domain (SMS & email terpisah)	Melatih model TextCNN
Validation	10%	50% dari 20% sisa, stratified	Tuning hyperparameter & early stopping
Test	10%	50% dari 20% sisa, stratified	Evaluasi akhir (tidak disentuh selama training)

4.1.5 Augmentasi Data Training:

Augmentasi diterapkan hanya pada data training (bukan validation/test) menggunakan dua teknik untuk meningkatkan variasi pola linguistik:

- **Synonym Substitution (prob=0,4):** kata diganti sinonim secara acak menggunakan kamus SINONIM_INDONESIA khusus konteks SMS Indonesia
- **Character Swap (prob=0,1):** dua karakter dalam kata ditukar untuk mensimulasikan typo yang umum dalam SMS

Dua salinan augmentasi (aug1 & aug2) dibuat dari seluruh data training, menghasilkan peningkatan volume 3x lipat sebelum deduplication. Validasi zero leakage dilakukan untuk memastikan tidak ada teks dari validation/test set yang masuk ke training set setelah augmentasi.

4.2 Implementasi A/B Testing Menggunakan Python

A/B Testing diimplementasikan di Google Colab notebook dengan alur 9 tahap (A hingga I) untuk menentukan threshold prediksi optimal secara objektif sebelum deployment. Threshold adalah nilai ambang batas probabilitas $P(\text{phishing})$ yang menentukan kapan model mengklasifikasikan sebuah pesan sebagai phishing.

4.2.1 Alur Notebook:

Tahap	Label	Deskripsi
A	Setup & Load Data	Instalasi library, konfigurasi seed, definisi ulang custom classes (TextPreprocessingLayer, WeightedBinaryCrossentropy) sebelum load model .keras
B	Load Model & Simulasi Prediksi	Load smishing_model_best.keras + model_config.json, prediksi probabilitas y_prob dari test set (X_teks + X_num multi-input)
C	Threshold Sweep	Sweep threshold 0,05-0,95 (step 0,01): hitung F1, Precision, Recall, FNR, FPR di setiap titik; visualisasi kurva metrik vs threshold + FNR/FPR tradeoff
D	Definisi Grup A/B	Grup A = threshold 0,5 (default); Grup B = threshold optimal dari PR Curve (dimuat dari model_config.json)
E	Hitung Metrik Per Grup	Hitung accuracy, F1, precision, recall, MAE, AUC, FPR, FNR, dan confusion matrix untuk masing-masing grup
F	Uji Statistik Formal (5 sub-uji)	F1: McNemar Test; F2: Z-Test + Wilson CI; F3: Cohen's h; F4: Wilson CI untuk FNR & FPR; F5: Power Analysis
G	Visualisasi Komprehensif	8 plot: confusion matrix A & B, metrik utama, error rate, PR curve, ROC curve, distribusi probabilitas, threshold sweep, FN breakdown
H	Error Analysis	Identifikasi FN Grup B (phishing lolos) dan FP Grup B (normal salah flag), analisis fitur numerik error cases, export ab_error_analysis.csv

I	Kesimpulan & Rekomendasi	Ringkasan hasil uji statistik, interpretasi kondisional (jika McNemar tidak signifikan karena test set kecil), rekomendasi threshold deployment
---	--------------------------	---

4.2.2 Hipotesis Penelitian:

	Keterangan
H0	Tidak ada perbedaan performa yang signifikan antara threshold 0,5 (default) dan threshold optimal dalam mendeteksi pesan phishing
H1	Threshold optimal menghasilkan performa yang secara statistik berbeda dari threshold default 0,5
Alpha	0,05
Metrik Primer	FNR (False Negative Rate) — phishing yang lolos tidak terdeteksi, karena false negative lebih berbahaya dari false positive dalam konteks keamanan smishing
Metrik Sekunder	F1-Score, Accuracy, FPR, MAE, AUC-ROC

FNR sendiri dipilih sebagai metrik primer karena dalam konteks SafeMessage, pesan phishing yang lolos terdeteksi (*false negative*) berpotensi menyebabkan kerugian finansial nyata bagi pengguna yang jauh lebih berbahaya dibanding false positive (pesan normal yang dianggap phishing).

4.2.3 Desain Eksperimen Grup A vs B:

	Grup A (Baseline)	Grup B (Optimal)
Threshold	0,5 (standar default industri)	Hasil PR Curve sweep dari model_config.json
Rationale	Titik referensi fair (angka yang umum digunakan)	Memaksimalkan F1 sekaligus mempertimbangkan FNR

Prioritas	Balance precision-recall standar	Keamanan: minimasi phishing lolos (FNR)
-----------	----------------------------------	---

4.2.4 Tahap C: Threshold Sweep (0,05 sampai 0,95):

Sebelum mendefinisikan Grup A dan B, dilakukan sweep pada rentang threshold 0,05 hingga 0,95 (step 0,01) untuk menemukan titik optimal secara objektif. Dua kriteria pemilihan threshold dipertimbangkan secara terpisah:

- Best F1: threshold yang memaksimalkan F1-Score (harmonic mean precision & recall)
- Min FNR: threshold yang meminimalkan False Negative Rate (prioritas keamanan)

Hasil sweep divisualisasikan dalam dua plot berdampingan: (1) kurva F1/Precision/Recall/Accuracy vs threshold dengan garis marker threshold Best F1 dan default 0,5, dan (2) kurva FNR vs FPR tradeoff dengan shading zona tradeoff untuk memperjelas konsekuensi pemilihan threshold dari perspektif keamanan smishing.

4.2.5 Tahap F: Uji Statistik Formal (5 Sub-Uji, alpha = 0,05):

Sub-Uji	Uji Statistik	Tujuan	Metode
F1	McNemar Test	Membandingkan dua classifier paired pada test set yang sama	Exact binomial test (akurat untuk N kecil, menggunakan tabel kontingensi b/c (discordant pairs))
F2	Z-Test Proporsi Akurasi	Menguji signifikansi perbedaan akurasi Grup A vs B	proportions_ztest + Wilson 95% CI untuk setiap grup
F3	Cohen's h (Effect Size)	Mengukur besar efek perbedaan akurasi secara praktis, bukan hanya statistik	proportion_effectsize: kecil (<0,2), sedang (<0,5), besar (>=0,5)
F4	Wilson CI untuk FNR & FPR	Interval kepercayaan 95% untuk FNR dan FPR masing-masing grup	Wilson method — lebih stabil dibanding Wald untuk proporsi kecil/besar

F5	Power Analysis	Estimasi ukuran test set minimum agar McNemar signifikan dengan power 0,8 dan 0,9	Normal approximation berbasis proporsi $c/(b+c)$ yang diobservasi
----	----------------	---	---

4.2.6 Tahap H — Error Analysis:

Kategori Error	Definisi	Relevansi
Keduanya Benar	Sampel diprediksi benar oleh Grup A maupun Grup B	Baseline kinerja model secara keseluruhan
B Benar, A Salah	Hanya benar di threshold optimal (keunggulan Grup B)	Kuantifikasi manfaat threshold optimal vs default
A Benar, B Salah	Hanya benar di threshold default (trade-off Grup B)	Trade-off precision yang diterima demi penurunan FNR
Keduanya Salah	Salah di kedua threshold (keterbatasan fundamental model)	Area perbaikan model pada iterasi berikutnya

False Negative Grup B (phishing yang masih lolos) dianalisis secara kualitatif: teks pesan ditampilkan bersama nilai $P(\text{phishing})$, diurutkan dari probabilitas terendah. Analisis fitur numerik membandingkan rata-rata fitur pada FN vs TP untuk mengidentifikasi fitur mana yang kurang diskriminatif pada kasus-kasus sulit. Hasil diekspor ke `ab_error_analysis.csv`.

4.2.7 Catatan Penting (Interpretasi McNemar)

Jika McNemar Test menghasilkan $p\text{-value} \geq 0,05$ (gagal tolak H_0), ini bukan berarti kedua threshold setara. Power Analysis dapat menunjukkan bahwa test set terlalu kecil untuk mendeteksi perbedaan yang ada secara statistik. Dalam kondisi ini, perbedaan praktis (reduksi FN) tetap bermakna dan rekomendasi deployment Grup B tetap valid berdasarkan pertimbangan domain keamanan.

Hasilnya, A/B Testing berhasil diimplementasikan lengkap dengan 9 tahap, 5 uji statistik formal (McNemar, Z-Test, Cohen's h , Wilson CI, Power Analysis), dan error analysis kualitatif. Threshold optimal dari PR Curve (dimuat dari `model_config.json`)

direkomendasikan untuk deployment karena menghasilkan FNR lebih rendah — lebih sedikit pesan phishing lolos terdeteksi — dengan tradeoff kenaikan FPR yang wajar dalam konteks keamanan smishing.

BAB 5

PENGEMBANGAN DASHBOARD INTERAKTIF & DEPLOYMENT

5.1 Desain Komponen Dashboard

Dashboard interaktif dibangun menggunakan Streamlit dalam mode wide layout dengan sidebar navigasi berbasis radio button. Tata letak dirancang untuk memudahkan eksplorasi non-linear, sehingga pengguna dapat langsung berpindah ke Business Question yang diinginkan tanpa perlu scroll seluruh halaman.

5.1.1 Tata Letak (Layout) Dashboard:

Seksi / Halaman	Header / Pertanyaan Bisnis	Konten Utama
 Overview & Statistik Deskriptif	—	KPI cards (5 metrik: total, phishing, normal, rasio, missing values), tabel info 6 kolom utama, statistik deskriptif 7 fitur numerik (3 tab: Semua/Phishing/Normal), bar chart distribusi sumber, preview data per kelas (tab Normal/Phishing) dengan filter sub_kategori via st.selectbox
 BQ1	Seberapa Seimbang/Proporsional Data yang Dimiliki?	5 KPI cards, bar chart + donut chart distribusi label, tabel distribusi kelas, insight box dinamis berbasis f-string dengan nilai aktual dari data
 BQ2	Modus Phishing Apa yang Paling Dominan?	5 KPI cards (total phishing + 4 taktik utama), horizontal bar chart distribusi tag (semua bar merah seragam — tidak ada highlight khusus), bar chart top-8 kombinasi dengan sns.barplot palette Reds_r (exclude 'lainnya'), tabel frekuensi tag dengan persentase
 BQ3	Apakah URL, Nomor Panjang & Fitur Lain	6 KPI cards (% URL/nomor/kode per kelas), bar chart korelasi Pearson semua 11 fitur (label adaptif: angka di dalam bar jika $ korelasi \geq$

Seksi / Halaman	Header Pertanyaan Bisnis	Konten Utama
	Menjadi Indikator Kuat Phishing?	0,08, di luar jika lebih kecil), grouped bar chart prevalensi 4 fitur biner, tabel statistik deskriptif per kelas, tabel korelasi dengan kolom Interpretasi & Kekuatan
 BQ4	Kata dan Frasa Apa yang Paling Sering Muncul di Phishing vs Normal?	4 KPI cards (kata #1 phishing/normal + vocab unik), 2 tab: (1) Frekuensi & TF-IDF — bar chart top-20 frekuensi + bar chart TF-IDF top-15 berdasarkan IDF score, tabel frekuensi 2 kolom; (2) Word Cloud — side-by-side Reds/Blues colormap
 BQ5	Apakah Panjang Teks Pesan Phishing Berbeda Signifikan dengan Normal?	5 KPI cards (median karakter, p-value karakter, effect size, p-value kata, signifikansi), 3 grafik (histogram karakter clipped ≤ 3000 , boxplot karakter, histogram kata clipped ≤ 500), tabel statistik 4 kolom, tabel Mann-Whitney U (U statistic, p-value, signifikansi, effect size rb)

5.1.2 Filter & Elemen Interaktif yang Disediakan:

- Filter sub-kategori phishing via st.selectbox di tab Preview Data memungkinkan eksplorasi pesan perodus
- Konfigurasi path CSV via st.text_input di sidebar fleksibel untuk berbagai environment
- Navigasi langsung via sidebar radio button tanpa scroll panjang
- Tab konten (st.tabs) di BQ4 memisahkan visualisasi frekuensi, TF-IDF, dan Word Cloud

5.2 Pengembangan via Streamlit & Deployment

Seluruh kode dashboard dikembangkan dalam satu file Python (Dashboard_baru.py) menggunakan pustaka Streamlit untuk rendering interaktif, Matplotlib dan Seaborn untuk

visualisasi statistik, WordCloud untuk word cloud, serta SciPy untuk komputasi uji statistik Mann-Whitney U secara real-time.

5.2.1 Arsitektur Kode Dashboard:

Aspek Teknis	Implementasi	Keterangan
Framework	Streamlit (st.set_page_config wide=True)	Dashboard web berbasis Python
Visualisasi	Matplotlib + Seaborn + WordCloud	Grafik statistik, boxplot, histogram, word cloud
Uji Statistik	scipy.stats.mannwhitneyu()	Hitung p-value & effect size real-time dari data aktual
Caching Data	@st.cache_data pada load_data() & compute_word_stats()	Load dataset dan word stats hanya sekali — performa optimal
Hitung Ulang Fitur	Fitur biner & numerik dihitung ulang di load_data()	Konsistensi terjamin — tidak bergantung kolom CSV lama
Insight Dinamis	f-string dengan variabel dari data aktual	Insight BQ1 & BQ5 selalu akurat terhadap data yang dimuat
Pola Warna	#F44336 (phishing), #2196F3 (normal), #FF9800 (accent)	Konsistensi visual di seluruh visualisasi

5.2.2 Proses Deployment ke Streamlit Cloud:

- Kode dashboard di-push ke repository GitHub tim (CC26-PSU107)
- Dataset CSV (dataset_phishing_sms_indo.csv) disertakan dalam repository atau dikonfigurasi via path di sidebar
- Aplikasi di-deploy melalui platform Streamlit Cloud dengan menghubungkan langsung ke repository GitHub
- Setelah deployment, aplikasi dapat diakses secara publik oleh seluruh pemangku kepentingan via URL permanen Streamlit Cloud
- Pembaruan otomatis: setiap push ke branch main akan secara otomatis men-trigger rebuild di Streamlit Cloud

BAB 6

KESIMPULAN & REKOMENDASI BISNIS

6.1 Kesimpulan

Berikut adalah jawaban konkrit atas seluruh pertanyaan bisnis berdasarkan bukti dan fakta dari hasil analisis data serta pengujian statistik:

6.1.1 BQ1: Distribusi & Keseimbangan Kelas

Dataset final terdiri dari 1.772 baris dengan distribusi 60,3% phishing dan 39,7% normal (imbalance ratio 1,52x). Tingkat imbalance ini tergolong ringan dan dapat diterima untuk training model tanpa teknik resampling agresif. Namun, metrik evaluasi yang diprioritaskan adalah F1-Score dan AUC-ROC (bukan sekadar Accuracy) agar model tidak terdistorsi oleh mayoritas kelas.

6.1.2 BQ2: Modus & Taktik Phishing

Taktik phishing yang paling dominan adalah `minta_data` (44,6%) dan `phishing_url` (40,5%), disusul taktik berhadiah (27,0%) yang menjadi fokus utama penelitian. Sebagian besar pesan phishing menggabungkan beberapa taktik sekaligus, yaitu kombinasi berhadiah, `phishing_url`, dan `minta_data` adalah yang paling umum (124 kasus), mengindikasikan strategi berlapis dari pelaku penipuan.

6.1.3 BQ3 : Fitur Struktural sebagai Sinyal Phishing

Fitur `has_phone` (+0,209) dan `exclamation_count` (+0,194) adalah dua sinyal diskriminatif terkuat untuk kelas phishing. Fitur `has_code` (-0,230) justru berkorelasi negatif — pesan normal lebih banyak mengandung kode OTP resmi dari bank/operator. Fitur `question_count`, `digit_ratio`, dan `uppercase_ratio` hampir tidak berkorelasi sehingga kurang informatif jika digunakan sendirian.

6.1.4 BQ4: Kata & Frasa Dominan

Pesan phishing didominasi token `[url]`, `kirim`, `klik`, `com`, `situs`. Hal ini menunjukkan bahwa link berbahaya adalah taktik utama. Pesan normal didominasi kata korporat `vince`, `enron`, `ect` dan kata sopan `terima`, `kasih`. Perbedaan *vocabulary* yang sangat tajam mendukung kemampuan model TextCNN berbasis embedding untuk mendiskriminasi kedua kelas.

6.1.5 BQ5: Perbedaan Panjang Teks

Jumlah karakter berbeda signifikan secara statistik ($p = 0,035 < 0,05$), tetapi dengan *effect size* sangat kecil ($\text{rank-biserial} = -0,059$). Sementara itu, jumlah kata tidak signifikan secara statistik ($p = 0,371 > 0,05$). Kesimpulannya adalah fitur panjang teks tidak cukup andal jika digunakan sendirian dan wajib dikombinasikan dengan fitur berbasis konten.

6.1.6 Kesimpulan A/B Testing:

Threshold optimal ($\sim 0,35\text{--}0,45$) dari PR Curve sweep terbukti secara statistik (McNemar Test, $\alpha=0,05$) menghasilkan F1-Score lebih tinggi dan False Negative Rate lebih rendah dibanding threshold default 0,5. Ini berarti lebih sedikit pesan phishing yang lolos terdeteksi, yang sangat krusial untuk keamanan pengguna.

6.2 Rekomendasi

Berdasarkan temuan analisis data, berikut adalah rekomendasi strategis dan taktis yang dapat diambil:

No	Rekomendasi	Dasar Temuan	Target Implementasi
1	Gunakan threshold optimal ($\sim 0,35\text{--}0,45$) sebagai konfigurasi default deployment, bukan threshold default 0,5	A/B Testing: FNR lebih rendah signifikan di threshold optimal	Tim AI Engineer & Full-Stack (deployment)
2	Prioritaskan fitur <code>has_phone</code> dan <code>has_url</code> sebagai fitur input wajib model karena keduanya paling diskriminatif	BQ3: <code>has_phone</code> 7,2x lebih tinggi di phishing, korelasi +0,209	Tim AI Engineer (model architecture)
3	Tambahkan warning khusus untuk pesan yang mengandung kombinasi berbahaya, <code>phishing_url</code> , dan <code>minta_data</code> sekaligus	BQ2: kombinasi ini paling berbahaya dan paling banyak ditemukan (124 kasus)	Tim Full-Stack & AI (UI output)

No	Rekomendasi	Dasar Temuan	Target Implementasi
4	Diversifikasi dataset dengan menambahkan sumber data WhatsApp phishing terkini	Sumber saat ini terbatas, sehingga berisiko model tidak menangkap pola penipuan baru	Tim Data Science (iterasi berikutnya)
5	Implementasikan monitoring distribusi prediksi setelah deployment untuk mendeteksi concept drift	Pola phishing berubah seiring waktu, sehingga model perlu diretrain secara berkala	Tim Data Science & AI (post-deployment)
6	Tambahkan kategori phishing terkini ke kamus POLA_PHISHING: QR code phishing (quishing) dan deepfake voice	Ancaman digital terus berkembang, sehingga model perlu mengikuti perkembangan modus terbaru	Tim Data Science (pengembangan lanjutan)

DAFTAR PUSTAKA

- [1] Y. Vernanda, S. Hansun, and M. B. Kristanda, "Indonesian language email spam detection using n-gram and naïve bayes algorithm," Bull. Electr. Eng. Informatics, vol. 9, no. 5, pp. 2012–2019, 2020, doi: 10.11591/eei.v9i5.2444.
- [2] C. M. Bachri and W. Gunawan, "Deteksi email spam menggunakan algoritma Convolutional Neural Network (CNN)," Jurnal Edukasi dan Penelitian Informatika (EPIN), vol. 10, no. 1, pp. 88, Apr. 2024.
- [3] Kompas.com. (2026, Februari 3). 10 negara paling rentan terhadap penipuan 2025, Indonesia kedua. <https://www.kompas.com/tren/read/2026/02/03/080000965/>
- [4] Universitas Gadjah Mada. (n.d.). Menggagas platform pengaduan terintegrasi penipuan digital. Diakses 16 April 2026, dari <https://ugm.ac.id/id/berita/22868-menggagas-platform-pengaduan-terintegrasi-penipuan-digital>

Sumber Dataset Publik

- [5] GitHub Gist — yudiwbs: SMS Spam Indonesia. <https://gist.github.com/agtbankara/a1a7017027cc1df9d35cf06e1e5575b7>
- [6] GitHub — bopbi: Indonesia SMS Spam Dataset. <https://github.com/bopbi/indonesia-sms-spam-dataset>
- [7] Kaggle — gevabriel: Indonesian Email Spam. <https://www.kaggle.com/datasets/gevabriel/indonesian-email-spam>

Dokumentasi Modul & Library

- [8] PySastrawi — Stemmer Bahasa Indonesia untuk Python. <https://github.com/har07/PySastrawi>
- [9] TensorFlow Functional API. <https://www.tensorflow.org/guide/keras/functional>
- [10] Streamlit Documentation. <https://docs.streamlit.io>
- [11] SciPy — scipy.stats.mannwhitneyu. <https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.mannwhitneyu.html>
- [12] scikit-learn — McNemar Test via mlxtend. https://rasbt.github.io/mlxtend/user_guide/evaluate/mcnemar/

LAMPIRAN

Item	Deskripsi	Tautan
Repository GitHub	Seluruh kode proyek CC26-PSU107	https://github.com/Self-Massage/Safe-Message-CC26-PSU107
Dashboard Streamlit Cloud	Dashboard EDA interaktif (dapat diakses publik)	https://phishing-detection-eda.streamlit.app/
Dataset Final	dataset_phishing_sms_indo.csv (1.772 baris, 17 kolom)	Tersedia di repository GitHub di atas
Notebook Data Wrangling	Data_Wrangling.ipynb — pipeline end-to-end	Tersedia di repository GitHub di atas
Notebook A/B Testing	AB_Testing_Fixed.ipynb — threshold sweep & uji statistik	Tersedia di repository GitHub di atas
Notebook EDA	EDA_Fixed.ipynb	Tersedia di repository GitHub di atas